Mineração de Métricas DORA em Repositórios Open-Source: quanto as conclusões dependem da definição operacional?

Bruna Costa Markowisk[1], **Pedro Luiz Nato Silva**[1], **Thiago Branco de Oliveira**[1]

Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Laboratório de Experimentação de Software – Prof. Danilo Maia

Abstract. *We mined the four DORA metrics for 350 popular GitHub repositories that use GitHub Actions and, since all metrics are proxies, measured how much conclusions change with the operational definition. The typical repository is DORA Medium: 0.40 releases/week, an 11-day lead time, 5.9% CI failure rate and 2.9 h recovery. Speed and stability show no trade-off under the CI failure rate ($\rho = 0.08$), but a delivery-based proxy reverses this ($\rho = 0.54$), largely as an arithmetic artifact: its corrective-release rule reaches F1 = 0.52 against a gold sample and is an upper bound. Between 14% and 33% of repositories change DORA category across definitions.*

Resumo. *Mineramos as quatro métricas DORA em 350 repositórios populares do GitHub que usam GitHub Actions e, como todas são aproximações, medimos o quanto as conclusões mudam com a definição operacional. O repositório típico é Medium: 0,40 release por semana, lead time de 11 dias, 5,9% de falha de CI e recuperação em 2,9 h. Pela falha de CI, não há trade-off entre velocidade e estabilidade ($\rho = 0{,}08$), mas um proxy de falha baseado em releases inverte o resultado ($\rho = 0{,}54$), em boa parte por aritmética: sua regra de release corretiva atinge F1 = 0,52 contra uma amostra-ouro e é um teto. Entre 14% e 33% dos repositórios mudam de categoria DORA conforme a definição.*

1 Introdução

As métricas DORA (*DevOps Research and Assessment*) são o padrão de mercado para medir o desempenho de entrega de software [Forsgren et al. 2018, DORA 2024]: duas de velocidade (frequência de deploy e lead time de mudanças) e duas de estabilidade (taxa de falha das mudanças, CFR, e tempo de recuperação). O GitHub, porém, não registra deploys nem falhas em produção, e qualquer estudo baseado em mineração de repositórios precisa estimá-las por aproximações (*proxies*). Este trabalho calcula as métricas em 350 repositórios e pergunta não só *qual é o valor* de cada métrica, mas *o quanto podemos confiar nele*.

As questões de pesquisa e as hipóteses informais são: **RQ01** (frequência de deploy): esperamos menos de uma release por semana no repositório típico. **RQ02** (lead time): esperamos de poucos dias a duas semanas por commit (variante b) e de duas a seis semanas por release (variante a), com (a) $\geq$ (b) em quase todos os repositórios, porque

um único commit antigo infla a variante por release. **RQ03** (CFR): esperamos CFR de CI entre 10% e 25%, com cauda acima de 45%, e um CFR de entrega menor, entre 5% e 15%, com correlação fraca entre os dois. **RQ04** (recuperação): esperamos mediana entre 1 hora e 1 dia, com cauda longa. **RQ05** (velocidade $\times$ estabilidade): seguindo a tese do DORA, esperamos que quem entrega mais falhe menos ($\rho < 0$). **RQ06** (características): esperamos efeitos pequenos a médios de contribuidores, popularidade, idade, linguagem e tipo do projeto. **RQ07** (sensibilidade): esperamos que mais de 10% dos repositórios mudem de categoria DORA quando a definição muda.

2 Metodologia

2.1 Fonte de dados, seleção e coleta

Os dados vêm das APIs REST e GraphQL do GitHub, por um pipeline próprio executado com um único comando, com cache em disco, retomada após interrupções e respeito à cota da API. A janela de observação vai de 01/10/2025 a 01/10/2026 e considera apenas o *default branch*. A busca foi fatiada em seis faixas de estrelas, porque devolve no máximo 1.000 resultados por consulta, e gerou 5.347 candidatos. Eles foram avaliados em ordem aleatória (semente 42) até 350 serem aprovados pelos critérios: usar GitHub Actions, ter ao menos 5 releases publicadas e ao menos 50 execuções de CI válidas (*push* no *default branch*) na janela (Tabela 1). A amostra tem 29 linguagens principais, mediana de 20.272 estrelas, 216 contribuidores e 6,7 anos de idade.

Tabela 1: Funil de seleção.

Etapa	Restantes	Descartados	Motivo
Candidatos da busca	5.347		
Avaliados (ordem aleatória)	1.185	4.162	alvo atingido
Usam GitHub Actions	1.022	163	sem workflows
≥ 5 releases na janela	437	585	releases insuficientes
≥ 50 runs válidos	350	87	runs insuficientes

Os commits de cada release vêm da comparação com a release anterior (`/compare`), com paginação completa; nenhuma lista ficou truncada. As execuções de CI foram consultadas mês a mês, com subdivisão dos intervalos que atingiam o teto de 1.000 resultados (912 de 6.374 consultas); nenhum intervalo ficou no teto. Foram 18.564 releases na janela, 2,8 milhões de commits entregues e 1,27 milhão de execuções de CI.

2.2 Definições operacionais

Deploy é uma release publicada (`draft = false`, `prerelease = false`). A **frequência** é o número de releases na janela dividido por 52,14 semanas. O **lead time** mede a distância entre a publicação da release e a data de autoria dos commits que ela entrega: (a) a partir do commit mais antigo, com mediana entre as releases do repositório; (b) a

partir de cada commit, com mediana sobre todos os commits. O **CFR (a)** é o número de execuções de CI com falha (`failure`, `timed_out`, `startup_failure`) dividido pela soma de falhas e sucessos; as demais conclusões são ignoradas. No **CFR (b)**, uma release R falha se, em até 7 dias, sai outra release da mesma linha (mesmo prefixo de tag e mesmo MAJOR.MINOR) com *patch* maior, tratada como corretiva; releases dos últimos 7 dias ficam fora do denominador (censura, 577 de 18.564). O **tempo de recuperação** é medido por workflow: um episódio começa na primeira falha após um sucesso e termina no próximo sucesso do mesmo workflow; o valor do repositório é a mediana dos episódios. A **classificação DORA** usa os cortes fixos da disciplina (Elite, High, Medium, Low), e a categoria geral é a mediana das quatro notas, arredondada para baixo.

2.3 Validação manual (amostra-ouro)

Sorteamos 60 repositórios (semente 42) entre os 348 com ao menos 5 releases avaliáveis e, de cada um, 5 releases, totalizando 300. Cada item recebeu três rótulos: tipo do projeto, se as releases são entregas reais e se a release é corretiva (seu objetivo principal é corrigir um defeito recente). A rotulagem foi realizada manualmente por Pedro Luiz Nato Silva, que examinou a lista de commits de todas as releases e consultou as notas de publicação ou o CHANGELOG em 232 delas, sem acesso à saída da heurística durante a avaliação. Como a classificação foi realizada por um único avaliador, não foi possível calcular a concordância interavaliadores pelo kappa de Fleiss. Das 300 releases, 113 (37,7%) são corretivas; em 58 dos 60 repositórios as releases são entregas reais.

2.4 Análise estatística

Reportamos mediana e IQR. Usamos Wilcoxon (uma amostra ou pareado), Spearman, Kruskal-Wallis com tamanho de efeito $\varepsilon^2 = H/(n-1)$ e correção de Holm (RQ06), kappa de Cohen ponderado linearmente e teste binomial (RQ07), com nível de 5%. Todo número deste artigo é reproduzível com três comandos a partir dos CSVs do repositório.

3 Resultados

A Tabela 2 resume as métricas, e a Figura 1 mostra as distribuições com os cortes DORA.

RQ01. A mediana equivale a uma release a cada 2,5 semanas; só 23% dos repositórios publicam ao menos uma por semana (Wilcoxon contra 1/semana: $p = 5{,}5 \cdot 10^{-15}$). Poucos projetos publicam quase automaticamente a cada mudança e formam uma cauda que chega a 26 releases por semana.

RQ02. As variantes se correlacionam fortemente ($\rho = 0{,}74$), e (a) supera (b) em 63% dos repositórios (Wilcoxon pareado unilateral: $p = 5 \cdot 10^{-4}$), mas a razão mediana (a)/(b) é só 1,36: com a mediana entre releases, o commit antigo "esquecido" pesa pouco. Das releases, 2.436 (13%) não trazem commits novos, e 0,36% dos commits têm lead time negativo (sinal de *rebase* ou *squash*).

Tabela 2: Métricas DORA por repositório: mediana (IQR) e distribuição nas faixas DORA.

Métrica	n	Mediana (IQR)	Elite	High	Medium	Low
Frequência (releases/semana)	350	0,40 (0,19–0,94)	2%	22%	46%	30%
Lead time (a) (dias)	350	10,9 (3,0–35,2)	13%	30%	28%	29%
Lead time (b) (dias)	350	11,7 (2,5–36,6)				
CFR (a), CI	350	5,9% (2,5–11,9%)	81%	13%	3%	4%
CFR (b), entrega (teto)	344	20,0% (8,7–48,8%)	38%	23%	12%	27%
Recuperação (horas)	334	2,9 (0,9–11,1)	26%	60%	12%	2%

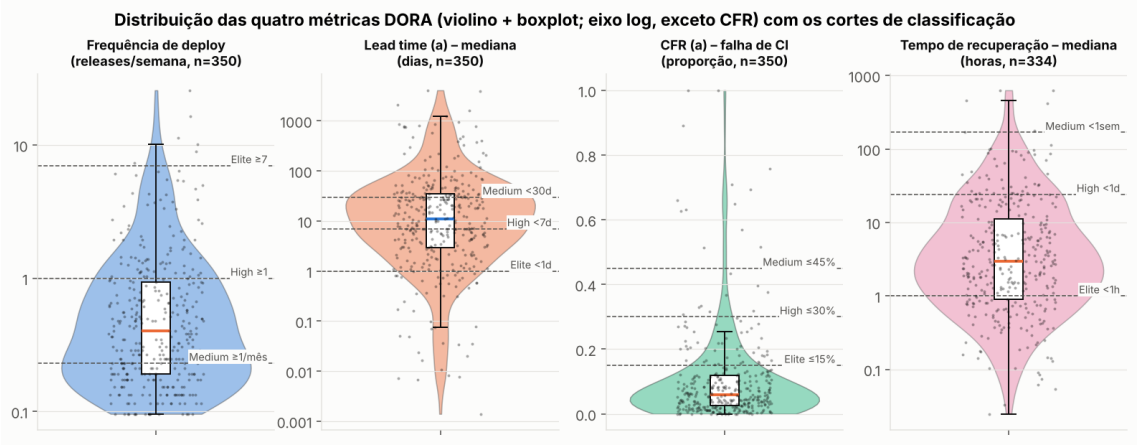


Figura 1: Distribuição das quatro métricas DORA, com os cortes de classificação.

RQ03. O CFR de CI é baixo: 81% dos repositórios estão na faixa Elite e só 14 passam de 45%. As variantes medem coisas diferentes (344 repositórios pareados: 5,7% contra 20,0%; Wilcoxon $p = 2 \cdot 10^{-27}$; correlação fraca, $\rho = 0{,}08$). Contra a amostra-ouro, a regra do CFR (b) tem precisão 0,56, recall 0,49 e **F1 = 0,52** (55 verdadeiros positivos, 43 falsos positivos, 58 falsos negativos e 144 verdadeiros negativos), abaixo do mínimo de 0,70. Os falsos positivos são *patches* que trazem funcionalidades, comuns em versões 0.x e monorepos. Como cada um faz uma release contar como falha, **o CFR (b) é um teto, não uma estimativa**. Sem o prazo de 7 dias, o critério de versão sozinho é mais preciso: 100 das 171 releases que são *patch* da mesma linha são corretivas, e 100 das 113 corretivas são *patches*.

RQ04. A recuperação é rápida: 86% dos repositórios têm mediana abaixo de 1 dia (Wilcoxon contra 24 h: $p = 2 \cdot 10^{-28}$). Por episódio (33.517), a mediana é 2,1 h, 32% se resolvem em menos de 1 h e o percentil 90 é 25 h. A distribuição é bimodal: falhas resolvidas por reexecução ou correção trivial (cerca de 1 h) e falhas que ficam para o dia seguinte (15 a 20 h). Só 125 de 33.642 episódios (0,37%) estavam abertos no fim da janela; a proporção mediana por repositório é 0%, e só 15 repositórios passam de 10%.

RQ05. Pela falha de CI, não há relação com a frequência ($\rho = 0{,}08$; $p = 0{,}13$; $n = 350$), e a recuperação melhora levemente com ela ($\rho = -0{,}16$; $p = 0{,}003$). Pelo CFR (b), a relação é forte e positiva ($\rho = 0{,}54$; $p = 4 \cdot 10^{-27}$), mas isso é em boa parte aritmética da definição (Figura 2): quem publica muito tem mais chance de publicar outra

release em 7 dias. A frequência se correlaciona com "ser seguida de qualquer release em 7 dias" ($\rho = 0{,}75$), não com a fração dessas que são *patches* ($\rho = -0{,}17$). A idade confunde a relação: ela vale $\rho = 0{,}65$ nos repositórios mais novos e desaparece nos mais antigos ($\rho = 0{,}09$).

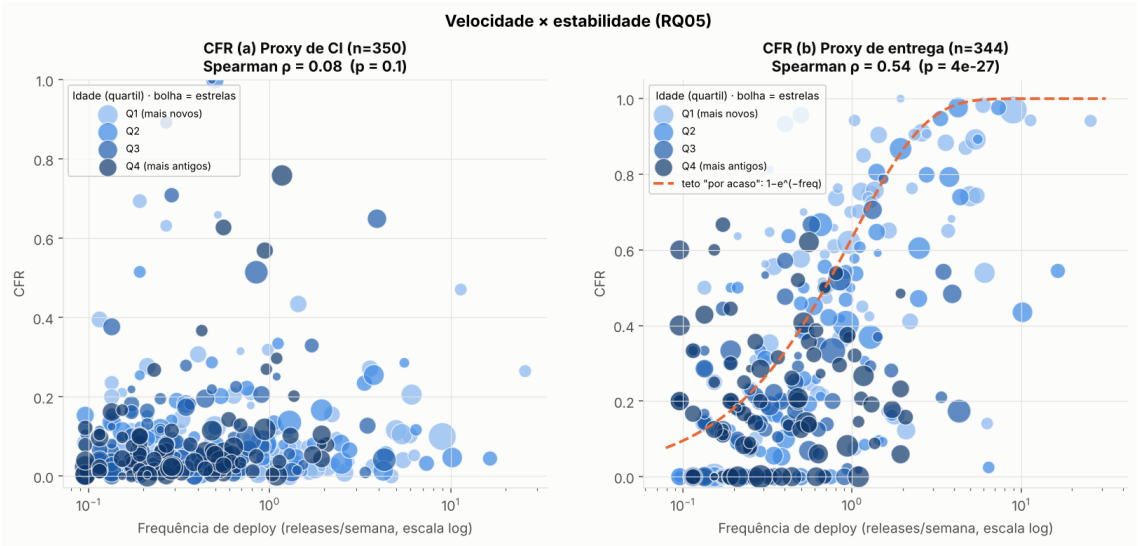


Figura 2: Frequência de deploy × CFR. A curva tracejada ($1 - e^{-\text{freq}}$) é o valor esperado por acaso no proxy de entrega.

RQ06. Cruzamos quatro fatores (linguagem, quartis de estrelas, de contribuidores e de idade) com cinco métricas, num total de 20 testes. Seis continuam significativos após Holm (Tabela 3). A idade é o fator mais forte (Figura 3): repositórios novos publicam mais (0,77 contra 0,27 release/semana), têm lead time menor (2,6 contra 22 a 26 dias) e CFR (b) muito maior (51% contra 14% a 19%). Mais contribuidores se associam a lead time *maior* (5,1 contra 24,5 dias), e Go tem o lead time mais longo (34 dias). Estrelas não se associam a nenhuma métrica, e as métricas de CI não variam com nenhum fator (p de Holm $\geq 0{,}73$; $n = 334$ a 350). Na amostra-ouro (60 repositórios), o tipo do projeto afeta só o lead time ($\varepsilon^2 = 0{,}21$; p de Holm $= 0{,}034$): ferramentas CLI levam 53 dias, bibliotecas 14 e aplicações 8. Como há grupos de 7 e 8 repositórios, esse resultado é indicativo.

Tabela 3: RQ06: testes significativos após Holm (Kruskal-Wallis).

Fator	Métrica	n	ε^2	p (Holm)
Idade	Lead time (a)	350	0,203	$< 0{,}001$
Idade	CFR (b)	344	0,144	$< 0{,}001$
Contribuidores	Lead time (a)	350	0,103	$< 0{,}001$
Linguagem	Lead time (a)	350	0,098	$< 0{,}001$
Idade	Frequência	350	0,094	$< 0{,}001$
Linguagem	CFR (b)	344	0,062	0,011

RQ07. Comparamos quatro combinações: C1 (referência: release, lead time a, CFR a), C2 (release e pré-release, lead time b, CFR b), C3 (muda só o lead time para

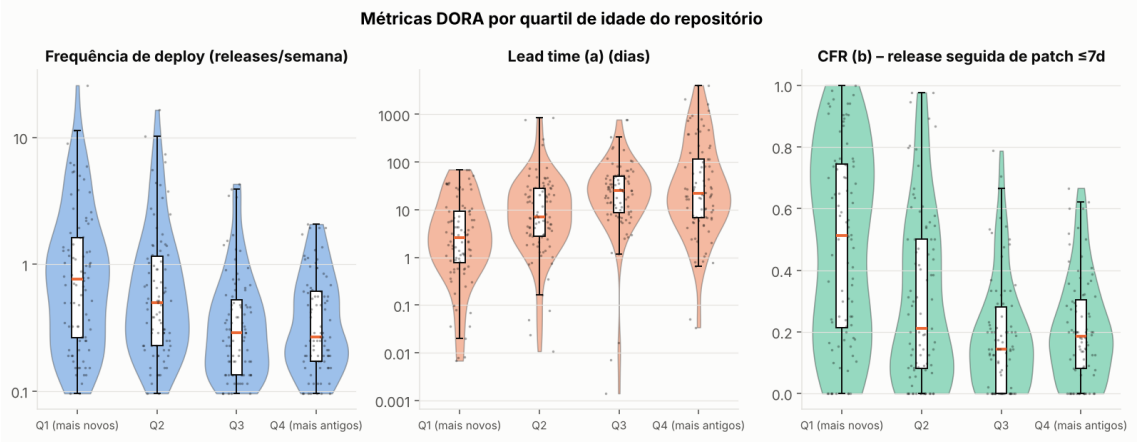


Figura 3: Frequência, lead time (a) e CFR (b) por quartil de idade.

b) e C4 (muda só o CFR para b). A variante com tags como unidade de deploy ficou fora, porque muitas tags não são entregas, e separá-las exigiria outra heurística sem validação. Entre 14% e 33% dos repositórios mudam de categoria, e todos os pares rejeitam a hipótese de no máximo 10% de mudança (Tabela 4 e Figura 4); a concordância vai de moderada a substancial na escala de [Landis e Koch 1977]. Trocar só o proxy de falha desloca 25% dos repositórios, quase todos para baixo; trocar só o lead time desloca 14%. A frequência, o lead time e a recuperação são conclusões robustas. A RQ05 e a parte da RQ06 que usa o CFR (b) dependem da definição.

Tabela 4: RQ07: concordância entre combinações de definições.

Par	n	Mudou de categoria	κ ponderado	p (mudança $\leq 10\%$)
C1 $\times$ C3 (só lead time)	334	14%	0,80	0,007
C2 $\times$ C4	328	16%	0,72	$4 \cdot 10^{-4}$
C1 $\times$ C4 (só CFR)	328	25%	0,61	$5 \cdot 10^{-15}$
C2 $\times$ C3	328	26%	0,61	$2 \cdot 10^{-16}$
C3 $\times$ C4	328	29%	0,54	$2 \cdot 10^{-22}$
C1 $\times$ C2 (tudo muda)	328	33%	0,47	$4 \cdot 10^{-29}$

4 Discussão

As conclusões mais confiáveis são as que se repetem em mais de uma definição: cadência de release lenta, CI estável com recuperação rápida e forte relação das métricas com a idade do projeto. Confirmamos as hipóteses da RQ01, da RQ04 e da RQ07 e a divergência entre variantes na RQ02 e na RQ03. Três resultados contrariaram as expectativas.

Primeiro, o CFR de CI (5,9%) ficou bem abaixo dos 10% a 25% esperados, e o de entrega (20%) bem acima dos 5% a 15%. A inversão vem da heurística: o CFR (b) conta como falha qualquer *patch* rápido, mesmo os que trazem funcionalidades. Segundo, a RQ05 não confirma a tese do DORA (quem entrega mais falha menos), mas também

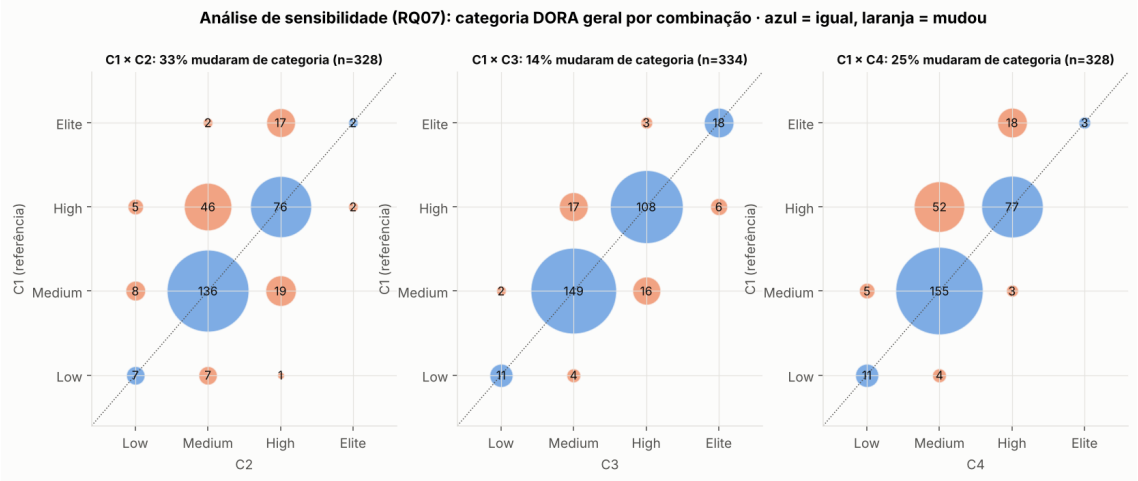


Figura 4: Categoria DORA geral na referência (C1) e nas demais combinações; azul indica categoria mantida e laranja, categoria alterada.

não a contradiz: pela falha de CI a relação é nula, e a recuperação melhora levemente com a frequência. O *trade-off* que aparece no CFR (b) é sobretudo um efeito mecânico da definição. Terceiro, mais contribuidores se associam a lead time maior, ao contrário do esperado, possivelmente por mais revisão e coordenação; e popularidade não explica nenhuma métrica. Por fim, a escolha do proxy de falha pesa mais na classificação DORA do que a do lead time: um estudo que reporte uma única categoria DORA por repositório deveria reportar também quão sensível ela é à definição.

5 Ameaças à validade

Organizamos as ameaças nas quatro categorias de [Wohlin et al. 2012].

Construto. A release não é o deploy: bibliotecas publicam versões, mas o deploy é feito por quem as usa, então medimos frequência de *publicação*. A falha de CI mede o *pipeline*, não a produção. O CFR (b) se apoia numa regra com F1 de 0,52 e deve ser lido como teto. As datas de autoria são distorcidas por *rebase* e *squash*.

Interna. A idade se correlaciona com frequência, lead time, CFR (b) e contribuidores; os testes da RQ06 são univariados e não separam os fatores. Repositórios muito ativos dominam a análise por episódio, então os testes foram feitos por repositório.

Externa. A amostra tem só repositórios populares ($\geq$ 1.915 estrelas), open-source, com GitHub Actions e com releases publicadas. Projetos que publicam só por tags ou gerenciadores de pacotes ficaram de fora (57% dos avaliados com Actions), assim como projetos corporativos com deploy real em produção. A janela de 12 meses reflete um momento com muitos projetos de IA jovens e ativos.

Conclusão. Com n de até 350, p-valores pequenos refletem poder estatístico, e por isso reportamos ρ e ε^2; aplicamos Holm nos 20 testes da RQ06. A amostra-ouro foi rotulada manualmente por Pedro Luiz Nato Silva, sem uma segunda avaliação indepen-

dente. Assim, não foi possível quantificar a concordância entre avaliadores, e o critério "release corretiva" permanece sujeito à interpretação humana, sobretudo em releases que misturam correções e funcionalidades. O tipo do projeto foi testado em apenas 60 repositórios.

6 Replicação cruzada

A replicação cruzada em uma amostra independente de repositórios fica indicada como etapa futura, para verificar a estabilidade das medidas e das classificações quando o pipeline é executado por outra equipe.

7 Conclusão

Repositórios open-source populares são tipicamente *Medium* no DORA: CI estável e recuperação rápida, mas cadência de release lenta e lead times de dias a semanas. Não há evidência de *trade-off* entre velocidade e estabilidade medida pelo CI. A idade é o fator mais associado às métricas, e a popularidade não importa. A mesma amostra produz de 14% a 33% de mudança de categoria conforme a definição, e a escolha do proxy de falha pesa mais que a do lead time. Como próximos passos, refinar a heurística de release corretiva incorporando as mensagens de commit, recalcular o CFR (b) com a versão validada e controlar idade e linguagem em conjunto.

Repositório do projeto: `https://github.com/Brunamark/DORA-metric`.

Referências

[DORA 2024] DORA (2024). DORA's software delivery metrics: the four keys. Disponível em: `https://dora.dev/guides/dora-metrics-four-keys/`.

[Forsgren et al. 2018] Forsgren, N., Humble, J. e Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press.

[Landis e Koch 1977] Landis, J. R. e Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

[Wohlin et al. 2012] Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B. e Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer.